

Arquitectura de escala e custos mensais expectáveis

Plano para servir folhetins verticais (modelo DramaBox) com 0,5 / 1 / 2 milhões de visualizações por dia. Pico simultâneo = sempre 10% dessas visualizações (50 k / 100 k / 200 k). Três cenários de vídeo: origem própria + CDN, Mux, Cloudflare Stream.

VOLUME BAIXO

0,5 M / dia

Pico **50 000** CCU · **100 Gbit/s**
15 M views · 0,29 PB · 19,5 M min

VOLUME MÉDIO

1 M / dia

Pico **100 000** CCU · **200 Gbit/s**
30 M views/mês · 0,59 PB · 39 M min

VOLUME ALVO

2 M / dia

Pico **200 000** CCU · **400 Gbit/s**
60 M views/mês · 1,17 PB · 78 M min

Custo expectável por mês (vídeo + app), USD, IVA excluído. Pico = 10% das views/dia.

Cenário	0,5 M/dia pico 50 k	1 M/dia pico 100 k	2 M/dia pico 200 k
A · HLS próprio + Bunny Volume	~ 3,0 k\$	~ 5,1 k\$	~ 8,3 k\$
B · Mux Vídeo 720p	~ 13,3 k\$	~ 24,8 k\$	~ 47,4 k\$
C · Cloudflare Stream	~ 20,8 k\$	~ 40,9 k\$	~ 80,8 k\$

AUDIÊNCIA

IT, arquitectura, financeiro

ÂMBITO

Plano de bits + plano de app

MOEDA

USD (factura cloud), IVA excl.

PRODUTO HOJE

Prototype Next.js + Storage MP4

DATA

16 Set 2026 · v1.1

FORA DE ÂMBITO

Pessoal, DRM, ads, aquisição

1. Resumo executivo

O TVI BOX de hoje serve MP4 progressivo a partir do Storage público do Supabase. Isso serve o prototype. **Não serve 50–200 mil pessoas a ver ao mesmo tempo.** O número que manda a arquitectura é o pico (10% das visualizações diárias em simultâneo), não a média. A média com 2 M views/dia são ~1 800 sessões; o pico são 200 000 — cerca de 110×.


Recomendação: **cenário A** (HLS próprio + CDN Bunny Volume ou Cloudflare Enterprise) para custo; **cenário B (Mux)** se a prioridade for tempo de chegada sem operar packager. O cenário C (Cloudflare Stream) é o mais simples e o mais caro à tabela pública.

A · DIY HLS + Bunny Volume B · Mux Video 720p C · Cloudflare Stream

Views / dia	Pico simultâneo (10%)	Pico de bits (720p)	Tráfego / mês	A · HLS + Bunny	B · Mux	C · CF Stream
0,5 milhões	50 000	100 Gbit/s	0,29 PB · 19,5 M min	~ 3,0 k\$	~ 13,3 k\$	~ 20,8 k\$
1 milhão	100 000	200 Gbit/s	0,59 PB · 39 M min	~ 5,1 k\$	~ 24,8 k\$	~ 40,9 k\$
2 milhões	200 000	400 Gbit/s	1,17 PB · 78 M min	~ 8,3 k\$	~ 47,4 k\$	~ 80,8 k\$

Totais = vídeo + app (Workers/API, Postgres, Redis, observabilidade, encoding de ingestão no A). Intervalo útil: ±25% conforme conclusão de episódio, mix ABR e região. Preços públicos Set 2026, sem desconto enterprise. O vídeo **não** pode passar pela Vercel (Fast Data Transfer 0,15 \$/GB tornaria 1,17 PB em ~175 k\$ só de egress).

Comparação visual dos totais mensais (escala = C a 2 M/dia = 80,8 k\$)



O que muda o custo

×3 a ×10

Entre A e C no mesmo volume. A diferença é quem opera o HLS e se pagas por minuto entregue ou por GB.

O que muda a arquitectura

110×

Pico vs média. Dimensionas CDN e Redis para o pico; Postgres e workers para a média + fila.

2. Hipóteses de tráfego

Parâmetro	Valor	Origem
Visualização	1 play de um episódio (start)	Definição de produto
Duração média	78 s (mediana 75 s; min 31 / máx 142)	Catálogo publicado TVI BOX, Set 2026
Bitrate de referência	2,0 Mbit/s a 720×1280 H.264	Medido nos MP4 importados (~1,5–2,5 Mbit/s)
Bytes por view	19,5 MB = 0,0195 GB	78 s × 2 Mbit/s / 8
Minutos por view	1,30 min	78 / 60
Mês	30 dias	Convenção orçamental
Pico simultâneo	10% das visualizações desse dia	Pedido de negócio (2 M → 200 k; 1 M → 100 k; 0,5 M → 50 k)
Conclusão / buffering	Entrega ≈ 1,0 × duração	Conservador (buffer HLS conta; skip reduz)

Views / dia	Views / mês	CCU médio	CCU pico (10%)	Pico / média	Gbit/s pico	PB / mês	M min / mês
0,5 M	15 M	451	50 000	111×	100	0,29	19,5
1 M	30 M	903	100 000	111×	200	0,59	39,0
2 M	60 M	1 806	200 000	111×	400	1,17	78,0

CCU médio = views/dia × 78 s / 86 400 s. Pico Gbit/s = CCU pico × 2 Mbit/s. Com ABR (360/540/720) o pico real de bits cai tipicamente para 50–70% deste valor; o contrato CDN dimensiona-se no pior caso (todos em 720p).

Alavanca n.º 1 — o feed autoplay. No prototype, o banner activo faz loop do episódio completo, muted. Com 200 k no «Para Ti» isso é outro canal de ~400 Gbit/s. Em produção: poster + clip de 3–5 s a 480p, ou um único segmento HLS.


3. O que o prototype actual não aguenta

Camada	Hoje	No pico
Vídeo	MP4 público no bucket Supabase <code>tvibox</code>	Origin não é CDN de 100–400 Gbit/s. Sem ABR. URL copiável fura o paywall.
Feed	Loop muted do episódio no banner visível	Pode duplicar o tráfego de vídeo.
Progresso	<code>POST /api/tvibox/progress</code> a cada 5 s	No pico de 200 k: ~40 000 writes/s na Postgres. A tabela e o PostgREST saturam.
App / auth	SSR Next.js + sessão Supabase em cada página	200 k aberturas simultâneas não cabem num plano Vercel Pro / Auth standard.
Vercel	Hosting do prototype	Se o MP4 passar na Fast Data Transfer (0,15 \$/GB após 1 TB), 1,17 PB ≈ 175 k\$ / mês.

O catálogo, a economia de moedas (`tvibox_unlock_episode`), o Estúdio e o worker de import (ffmpeg + Whisper) **mantêm-se**. O que muda é o caminho do ficheiro até ao telemóvel e o que a app escreve na base a cada segundo.

4. Arquitectura alvo

Dois planos que nunca se misturam: **plano de bits** (vídeo no CDN) e **plano de app** (login, moedas, catálogo).



4.1 Plano de vídeo

- Deixar de servir MP4 progressivo ao público. No `tvibox:import`, gerar HLS/CMAF com três rendições: 360p (~0,5 Mbit/s), 540p (~1 Mbit/s), 720p (~2 Mbit/s).
- Origin no R2 ou Bunny Storage. CDN com $\geq 95\%$ de hit. O bucket Supabase fica para o Estúdio / origin privado.
- URL assinada (JWT ou cookie, 2–5 min, amarrada a utilizador + episódio). O EP2 não existe como URL público.
- Player: HLS nativo no iOS + `hls.js` no resto.

4.2 Plano de app

- Catálogo em cache de borda 30–60 s (quase estático).
- Carteira / unlocks / progresso: Redis à frente, Postgres atrás. Manter a RPC atômica `tvibox_unlock_episode`.
- Pool de 200–500 ligações Postgres, nunca 50–200 k. Rate limit por utilizador no Redis.
- Pior caso (todos a desbloquear o EP2 no mesmo cliffhanger): fila curta com idempotência; a UI mostra «A desbloquear...».
- Progresso: só no fim do episódio + a cada 30 s, via fila — não a cada 5 s.
- Auth: JWT validado na borda. O GoTrue aguenta o login, não 200 k `getUser()` por heartbeat.

4.3 Hosting da app

Manter Next.js, **tirar o vídeo da Vercel**. Cloudflare Workers/Pages para `/tvibox` (PoP em Lisboa, sem egress de vídeo) ou Vercel Enterprise só para HTML/API com o player a apontar para o CDN de vídeo. Estúdio, import e Whisper **não** precisam deste scale — continuam no worker com `ffmpeg`.

5. Os três cenários

A — Custo baixo, ops vossas (recomendado a prazo)

Packager HLS no import já existente → origin R2 ou Bunny Storage → CDN Bunny **Volume** (ou Standard EU se a qualidade de PoP em Portugal o justificar) → player HLS. App em Workers + Postgres always-on + Redis.

Bunny Volume (docs oficiais): 0–500 TB a 0,005 \$/GB; 500 TB–1 PB a 0,004; 1–2 PB a 0,003. 10 PoPs. Confirmar com o sales o pico de 100–400 Gbit/s. A página comercial ainda lista 0,002 \$/GB no último escalão — usámos 0,003 (conservador, +170 \$ no patamar de 2 M/dia). Alternativa: Cloudflare Enterprise + R2 — sem preço de lista para 1 PB de streaming; só com proposta (ordem de grandeza 8–20 k\$ no patamar de 2 M/dia).

B — Tempo de chegada (recomendado se o prazo apertar)

Mux Video a 720p: ingestão, ABR, CDN multi-POP e player. Pagas por minuto entregue, com desconto de volume acima de 10 M min/mês (último escalão público 0,00056 \$/min). A app é a mesma do A, sem packager próprio.

C — Um fornecedor, factura simples

Cloudflare Stream: 1 \$ / 1 000 minutos entregues na tabela pública, encoding e bandwidth incluídos. Há volume via sales; sem contrato fica o mais caro dos três.

6. Custos desagregados (USD / mês)

App (comum aos três, escala com o volume): Workers/API, Postgres always-on, Redis, observabilidade QoE, encoding de ingestão no A. No B e C o encoding de entrega vai no preço do vídeo.

Linha	0,5 M / dia pico 50 k	1 M / dia pico 100 k	2 M / dia pico 200 k
Tráfego de referência			
Views / mês	15 M	30 M	60 M
Minutos entregues	19,5 M	39 M	78 M
Egress (720p, 19,5 MB/view)	293 TB	585 TB	1 170 TB
A — CDN Bunny Volume (só vídeo)			
CDN Volume (0,005 / 0,004 / 0,003 \$/GB)	1 463 \$	2 840 \$	5 010 \$
Storage origin HLS (3 ladders)	< 50 \$	< 50 \$	< 50 \$
App + DB + Redis + QoE + ingest	1 500 \$	2 200 \$	3 200 \$
A total	~ 3 000 \$	~ 5 100 \$	~ 8 300 \$
B — Mux Video 720p (tabela pública, último escalão 0,00056 \$/min)			
Entrega Mux	11 940 \$	22 860 \$	44 700 \$
Storage Mux	desprezável	desprezável	desprezável
App + DB + Redis + QoE	1 300 \$	1 900 \$	2 700 \$
B total	~ 13 300 \$	~ 24 800 \$	~ 47 400 \$
C — Cloudflare Stream (1 \$ / 1 000 min, tabela pública)			
Minutos entregues Stream	19 500 \$	39 000 \$	78 000 \$
App + DB + Redis + QoE	1 300 \$	1 900 \$	2 700 \$
C total	~ 20 800 \$	~ 40 900 \$	~ 80 800 \$

6.1 Sensibilidade Bunny Standard EU

Se o tráfego for sobretudo Portugal/UE e se preferir a rede Standard (0,01 \$/GB EU, 119 PoPs) em vez da Volume:

	0,5 M · pico 50 k	1 M · pico 100 k	2 M · pico 200 k
CDN Standard EU (0,01 \$/GB × TB)	2 925 \$	5 850 \$	11 700 \$
A total com Standard EU (em vez de Volume)	~ 4 500 \$	~ 8 100 \$	~ 15 000 \$

Mistura 20% Ásia/África na Standard sobe o GB (0,03–0,06 \$). Volume continua a ser o tecto baixo se o sales confirmar o pico de Gbit/s.

6.2 O que não fazer (mesmo volume, 2 M/dia)

Caminho	Resultado
MP4 no Supabase Storage	Origin não aguenta 400 Gbit/s; paywall furável
Vídeo pela Vercel	~175 k\$ de Fast Data Transfer
CloudFront + S3 sem contrato	~60–90 k\$ de egress
Cloudflare Pro/Business a 400 Gbit/s de vídeo	Fair use; empurram para Enterprise ou Stream

7. App — custos de referência (incluídos nos totais)

Componente	0,5 M / dia	1 M / dia	2 M / dia
Cloudflare Workers (~50 / 100 / 150 M req)	20–50 \$	40–80 \$	50–150 \$
Postgres always-on (4 → 8 vCPU)	200–400 \$	350–600 \$	500–900 \$
Redis (sessão + carteira quente)	50–120 \$	80–200 \$	150–300 \$
Observabilidade / QoE	300–600 \$	500–1 000 \$	800–1 500 \$
Ingest ffmpeg (só A; B/C incluído no vídeo)	100–250 \$	150–300 \$	200–400 \$

Workers a 0,30 \$/milhão de requests depois de 10 M incluídos: mesmo a 150 M req/mês são ~50 \$. A Postgres **não** escala para 200 k ligações — escala para 200–500 via PgBouncer. Redis no pico de 200 k sessões × ~2 kB ≈ 400 MB de working set.

8. Riscos e alavancas

- 1. **Pico 111× a média.** CDN e Redis para 50/100/200 k CCU. Postgres e workers para a média + fila no pico.
- 2. **Feed autoplay** pode igualar o custo do player. Clip curto obrigatório.
- 3. **ABR paga-se a si próprio.** Sem 360p, toda a gente no comboio puxa 2 Mbit/s e o pico de 100/200/400 Gbit/s é real.
- 4. **Conclusão de episódio.** Se a view média for 20 s e não 78 s, tráfego e factura caem ~4×. Os números desta tabela são o tecto (view ≈ episódio completo).
- 5. **Contrato CDN antes da campanha.** Nenhum plano self-serve aguenta 200 k CCU de vídeo na primeira estreia.
- 6. **Paywall real** só com URL assinada. O `video_url` público actual não pode ir para o cliente.

9. Ordem de implementação (prototype → produção)

- 1. Packager HLS no `tvibox:import` + origin R2/Bunny + player HLS. O Estúdio não muda para o editor.
- 2. Signed URLs no unlock; o cliente deixa de receber o MP4 público.
- 3. Preview do banner: clip de 5 s, não o MP4 do EP1.
- 4. Progresso para fila (30 s / complete).
- 5. Redis à frente de carteira, unlocks e rate limit; Postgres fica fonte de verdade.
- 6. Contrato CDN (Bunny Volume/Standard ou CF Enterprise / Mux) **antes** de qualquer campanha no patamar de 50 k+ CCU.
- 7. Mux ou Stream só se se quiser saltar os passos 1–5 e pagar 3–10×.

10. Anexo — fórmulas e preçários usados

```
views_mês = views_dia × 30
minutos = views_mês × 78 / 60
TB = views_mês × 0,0195 / 1 000
CCU_pico = 0,10 × views_dia
Gbit/s_pico = CCU_pico × 2 / 1 000
CCU_médio = views_dia × 78 / 86 400
```

11. Folha de decisão para IT

Esta página é o briefing para a reunião de arquitectura. Os números da capa repetem-se aqui com o pedido de cotação e a checklist técnica.

Critério	A · HLS + Bunny Volume	B · Mux 720p	C · Cloudflare Stream
Custo / mês 0,5 · 1 · 2 M	3,0 · 5,1 · 8,3 k\$	13,3 · 24,8 · 47,4 k\$	20,8 · 40,9 · 80,8 k\$
Quem opera o HLS	Nós (packager no import)	Mux	Cloudflare
Tempo até à 1.ª estreia à escala	Packager + contrato CDN	Dias (SDK + tokens)	Dias (Stream + signed URLs)
Pico 100 / 200 / 400 Gbit/s	Contrato Volume obrigatório	Incluído na entrega	Incluído na entrega
Paywall (URL assinada)	A construir (JWT/cookie)	Playback tokens Mux	Signed URLs Stream
ABR 360 / 540 / 720	ffmpeg no import	Mux	Stream
Vendor lock-in	Baixo (ficheiros vossos)	Médio	Médio
Quando escolher	Custo e catálogo próprio a prazo	Estreia rápida sem ops de vídeo	Um fornecedor, aceitar 10× o A

Pedido de cotação (copiar para o sales)

Plataforma de VOD vertical 9:16, origem UE (Lisboa). Três patamares, pico = 10% das views/dia:

- **0,5 M views/dia** — 50 000 CCU, 100 Gbit/s, 293 TB/mês, 19,5 M min
- **1 M views/dia** — 100 000 CCU, 200 Gbit/s, 585 TB/mês, 39 M min
- **2 M views/dia** — 200 000 CCU, 400 Gbit/s, 1 170 TB/mês, 78 M min

Pedir: committed bandwidth no pico, hit ratio origin, PoPs em PT/ES/FR, token auth, e o preço com e sem ABR. Bunny: Volume vs Standard EU. Cloudflare: Enterprise + R2 vs Stream. Mux: 720p basic, committed minutes.

Checklist antes de qualquer campanha ≥ 50 k CCU

1. Vídeo fora da Vercel e fora do bucket público Supabase.
2. HLS (próprio ou Mux/Stream) com 360/540/720 e URL assinada por utilizador + episódio.
3. Banner «Para Ti»: clip de 3–5 s, nunca o episódio completo em loop.
4. Progresso em fila (30 s / complete), não a cada 5 s.
5. Redis à frente de carteira e unlock; Postgres com PgBouncer 200–500 ligações.
6. Contrato CDN/Mux assinado com o Gbit/s e o PB desta tabela — não self-serve.
7. Teste de carga: 10% do pico alvo (5 / 10 / 20 k CCU) antes da estreia.

Preçários usados

Mux 720p (entrega, \$/min): primeiros 0,5 M → 0,00080; +0,5 M → 0,00076; +1 M → 0,00072; +4 M → 0,00067; +4 M → 0,00061; >10 M → 0,00056. Primeiros 10 M min = 6 620 \$; o resto a 0,00056. Crédito de 100 k min/mês irrelevante nesta escala.

Cloudflare Stream: 5 \$ / 1 000 min armazenados (irrelevante no catálogo); 1 \$ / 1 000 min entregues.

Bunny Volume (docs): 0,005 / 0,004 / 0,003 \$/GB nos patamares 0–500 TB / 500 TB–1 PB / 1–2 PB. docs.bunny.net/cdn/pricing , Set 2026.

Catálogo TVI BOX (duração média 78 s). Documento de planeamento — não é proposta comercial dos fornecedores. Regenerar: npm run tvibox:escala-pdf .